



## (12) 发明专利

(10) 授权公告号 CN 114004409 B

(45) 授权公告日 2024. 12. 06

(21) 申请号 202111301713.8

(22) 申请日 2021.11.04

(65) 同一申请的已公布的文献号

申请公布号 CN 114004409 A

(43) 申请公布日 2022.02.01

(73) 专利权人 东南大学

地址 211135 江苏省南京市麒麟科创园智  
识路26号启迪城立业园04幢

(72) 发明人 王帅 周智圆 梅洛瑜

(74) 专利代理机构 南京众联专利代理有限公司

32206

专利代理师 杜静静

(51) Int. Cl.

G06Q 10/047 (2023.01)

G06Q 10/0835 (2023.01)

G06Q 30/0601 (2023.01)

G06N 3/048 (2023.01)

G06N 3/08 (2023.01)

(56) 对比文件

CN 109002960 A, 2018.12.14

CN 110414731 A, 2019.11.05

审查员 武茹茹

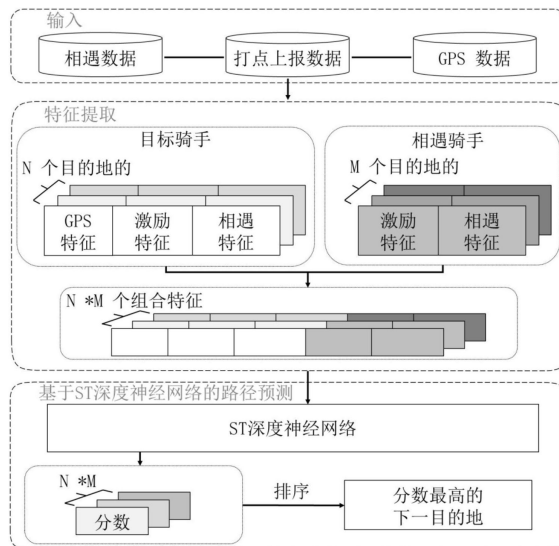
权利要求书3页 说明书6页 附图2页

(54) 发明名称

一种基于多源数据的即时配送路径预测方法

(57) 摘要

本发明涉及一种基于多源数据的即时配送路径预测方法,包括预测系统,其中预测系统包括个多源特征提取模块,实现特征层面的数据融合;以及一个基于深度神经网络的路径预测模块,基于多源特征预测骑手路径,完成模型层面的特征融合;该技术首先关联多源异构数据——骑手相遇数据、骑手打点上报数据、骑手GPS数据提取得到多源特征,然后将多源特征进一步进行特征组合。得到的一系列组合特征通过基于包含特征转换层的深度神经网络,输出得到一系列预测分数,最终通过分数排序得到分数最高的即时配送骑手的下一目的地,即路径预测结果。该技术利用了包含丰富时空信息的多源数据,消除了单一数据源低质量的影响,可以有效提高路径预测的准确率。



1.一种基于多源数据的即时配送路径预测方法,其特征在于,包括预测系统,其中预测系统包括个多源特征提取模块,实现特征层面的数据融合;以及一个基于深度神经网络的路径预测模块,基于多源特征预测骑手路径,完成模型层面的特征融合;

所述方法包括以下步骤:

S1.从即时配送平台提取骑手打点上报数据、骑手相遇数据、骑手GPS数据;

S2.考虑多源数据的独立性与关联性,对多源数据进行多源特征提取与融合;

S3.使用特征转换层提炼多源特征的高维特征表达,基于深度神经网络预测即时配送路径;

其中,步骤S2的多源特征提取与融合工作,从多源数据中提取了目标骑手目的地与目标骑手的相遇骑手的目的地多源组合特征,实现了特征层面的数据融合,具体工作如下:

从多源数据中提取的三类特征分别是:相遇特征、GPS特征和激励特征,针对目标骑手的每个目的地,提取三类特征;针对目标骑手配送途中最近一次遇到的相遇骑手的每个目的地,提取两类特征即激励特征和相遇特征,然后取这两个骑手即目标骑手和相遇骑手的目的地特征的笛卡尔乘积得到组合特征,即 $A \times B = \{(a, b) | a \in A \wedge b \in B\}$ ,每个组合特征代表目标骑手目的地和相遇骑手目的地的一种组合;具体如下,当目标骑手有N个目的地,而他在配送途中遇到的骑手有M个目的地时,模型首先从骑手打点上报数据、相遇数据以及GPS数据中提取出目标骑手N个目的地特征,以及相遇骑手M个目的地特征,然后得到 $M \times N$ 个组合特征;

步骤S3设计的ST(Specialized Transition)深度神经网络完成了模型层面的特征融合,实现了目标骑手的下一个目的地预测,具体工作如下:

路径预测模块的关键部分是基于深度神经网络的ST网络,ST网络预测了每个骑手目的地组合的可能性,ST网络对激励特征 $x^I$ 、相遇特征 $x^E$ 和GPS特征 $x^G$ 三类特征进行了不同的特征转换,每个特征转换由三层组成:输入层、隐藏层和输出层,经过特征转换得到的新特征向量最后通过全连接层连接在一起,利用sigmoid激活函数输出得分;

经过特征转换得到的新特征向量 $k$ 由 $k = K(x | W_h, W_o, b_h, b_o)$ 表示,其中 $K(\cdot)$ 为由 $W_h, W_o, b_h, b_o$

参数化的特征转换函数, $K(\cdot)$ 分解为

$$h = \text{ReLU}(W_h x + b_h),$$

$$k = \text{ReLU}(W_o h + b_o);$$

其中, $x$ 为输入特征向量, $h$ 为隐含层的输出, $W_h, b_h$ 为隐含层的权值和偏差, $W_o, b_o$ 为输出层的权值和偏差,隐含层和输出层使用的激活函数为ReLU,不同特征转换函数的参数是相互独立的;

对于目标骑手的目的地 $d_i$ ,通过GPS特征转换得到新的GPS矢量 $k^G$ ,

$$k^G = K(x_{d_i}^G | W_h^G, W_o^G, b_h^G, b_o^G);$$

与骑手的GPS特征 $x_{d_i}^G$ 相比,它与 $d_i$ 被选为下一个目的地的可能性有更强的相关性,基于目的地激励特征 $x_{d_i}^I, x_{d_j}^I$ ,新的激励向量 $k_i^I, k_j^I$ 分别表示目的地 $d_i, d_j$ 被骑手 $c_p, c_e$ 选择的可能性;

$$k_i^I = K(x_{d_i}^I | W_h^I, W_o^I, b_h^I, b_o^I),$$

$$k_j^I = K(x_{d_j}^I | W_h^I, W_o^I, b_h^I, b_o^I);$$

ST网络的特点之一是共享目标骑手 $c_p$ 和相遇骑手 $c_e$ 的激励特征转换层参数;

因为需要共同分析目标骑手和相遇骑手的相遇特征得到骑手相遇可能性,所以需将两个骑手 $c_p, c_e$ 的相遇特征 $x_{d_i}^E, x_{d_j}^E$ 拼接,然后输入到相遇特征转换层来获得新的相遇向量 $k^E$

$$k^E = K([x_{d_i}^E, x_{d_j}^E] | W_h^E, W_o^E, b_h^E, b_o^E);$$

新向量 $k^E$ 与相遇概率密切相关,相遇概率又与下一个目的地的正确性密切相关,最后,ST网络联合分析这些新的向量,并输出目标骑手目的地 $d_i$ 的最终预测得分 $p$ ,

$$p = \delta(W_f[k^G, k^E, k_i^I, k_j^I] + b_f);$$

其中 $W_f, b_f$ 是全连接层的权值和偏差,

ST网络的预测任务是判断目的地组合是否正确,设 $y$ 为样本标签,值为0或1,使用交叉熵损失函数对网络进行训练,即损失函数为

$$\text{Loss} = -[y \ln(p) + (1-y) \ln(1-p)],$$

对于每个组合特征,通过ST网络得到预测得分,对得分进行排序,得分最高的组合特征所代表的目标骑手的目的地即为预测结果(即目标骑手的下一个目的地);

$$x_{i,j}^{cb} = [x_{d_i}^G, x_{d_i}^E, x_{d_i}^I, x_{d_j}^E, x_{d_j}^I],$$

$$p = M_{ST}(x^{cb}),$$

$$\hat{d} = F_{tol}(\hat{x}^{cb}),$$

$$\hat{x}^{cb} = \text{argmax}[M_{ST}(x_{i,j}^{cb})];$$

整个路径预测过程可以用以上方程表示, $\hat{d}$ 表示预测得到的目标骑手下一个目的地, $M_{ST}(\cdot)$ 表示ST网络函数, $F_{tol}(\cdot)$ 表示组合特征 $x_{i,j}^{cb}$ 与目标骑手目的地 $d$ 的映射函数。

2. 根据权利要求1所述的基于多源数据的即时配送路径预测方法,其特征在于,S1.从即时配送平台提取骑手打点上报数据、骑手相遇数据、骑手GPS数据,具体如下:平台要求骑手在接受订单、到达商家、领取订单、交付订单时主动在手机应用程序上报告订单进度,平台通过骑手的打点上报数据获得订单、骑手的实时状态;平台使用Beacon技术收集骑手相遇信息,其原理如下:通过手机应用程序,使骑手手机在其工作时间内通过BLE 5.0即蓝牙5.0协议持续广播一个ID tuples并进行持续扫描以感知蓝牙信号,再通过网络连接实时将扫描接收到的ID tuples上传到后端服务器,服务器接收到骑手ID和骑手接收到的ID tuples后,提取得到骑手相遇数据;平台通过骑手手机GPS定位获取骑手GPS数据。

3. 根据权利要求2所述的基于多源数据的即时配送路径预测方法,其特征在于,三类特征具体定义如下:

A. 相遇特征,相遇发生在从某个出发点前往目的地的路程中,通过将骑手相遇数据与骑手打点上报数据相关联,提取得到相遇事件发生时骑手的出发点位置相遇特征;假设目标骑手 $c_p$ 和相遇骑手 $c_e$ 的下一个目的地分别为 $d_i$ 和 $d_j$ ,如果根据目标骑手 $c_p$ 和相遇骑手 $c_e$ 的

相遇特征 $x^E = \{L_o, L_d, t_e\}$ 发现他们不可能相遇,则推断下一目的地为 $d_i$ 和 $d_j$ 的假设是错误的,

B.GPS特征,设下一个目的地为 $d_i$ ,则 $t$ 时刻的骑手GPS特征包括从GPS数据中提取的骑手当前所在位置的地理位置 $L_g$ ,以及从打点上报数据中提取的 $L_o, L_d$ ,利用GPS特征 $x^G = \{L_g, L_o, L_d\}$ ,判断骑手当前的轨迹方向是否与到达目的地的方向 $d_i$ 一致,从而验证目的地 $d_i$ 是否为下一个目的地;

C.激励特征,对于骑手 $c$ ,在 $t$ 时刻,他有一组目的地集合 $D_{c,t}$ ,从打点上报数据中提取这些目的地的激励特征 $x^I = \{s, s_n, \bar{s}, t_{lo}, t_u, t_{ld}, t_g, v_p, v_c, v_{ps}\}$ ,激励特征由时间、空间、场景三类特征构成。

## 一种基于多源数据的即时配送路径预测方法

### 技术领域

[0001] 本发明涉及一种基于多源数据的即时配送路径预测方法,属于计算机数据处理技术领域。

### 背景技术

[0002] 即时配送服务为了确保服务质量,有严格的订单交付时限。然而,由于交通、天气和时空等因素的影响,难以避免订单超期。准确预测即时配送场景下的骑手配送路径有利于将新订单分配给最合适的骑手,提高配送效率,降低订单超时率。

[0003] 现有的路径预测算法大多基于单源数据,比如GPS轨迹数据或订单物流信息。这些方法不能应对实际情况中多种复杂因素,例如即时配送中的多个目的地和骑手个体差异。此外,现有的大多数研究往往使用启发式算法优化骑手的配送路径,并将优化的配送路径推荐给骑手。这些研究假设骑手的实际路径与推荐路径一致。然而,在现实中,骑手可能更愿意根据自己的经验来规划路径,而不是严格遵循建议。根据研究,至少有20%骑手的决定与推荐路径不同。这样的问题导致订单分派算法性能的下降。

[0004] 由此可知,现有的技术无法实现准确的骑手路径预测,以准确率较低的骑手路径预测结果作为数据基础进行的订单分派,配送效率低,影响了即时配送服务的服务质量,因此,迫切的需要一种新的方案解决上述技术问题。

### 发明内容

[0005] 本发明正是针对现有技术中存在的问题,提供一种基于多源数据的即时配送路径预测方法,该技术方案通过融合多源异构数据,使用深度神经网络模型准确预测骑手配送路径。

[0006] 为了实现上述目的,本发明的技术方案如下,基于多源数据的即时配送路径预测方法,其特征在于,包括预测系统,其中预测系统包括个多源特征提取模块,实现特征层面的数据融合;以及一个基于深度神经网络的路径预测模块,基于多源特征预测骑手路径,完成模型层面的特征融合;

[0007] 所述方法包括以下步骤:

[0008] S1.从即时配送平台提取骑手打点上报数据、骑手相遇数据、骑手GPS数据;

[0009] S2.考虑多源数据的独立性与关联性,对多源数据进行多源特征提取与融合;

[0010] S3.使用特征转换层提炼多源特征的高维特征表达,基于深度神经网络预测即时配送路径。

[0011] 作为本发明的一种改进,S1.从即时配送平台提取骑手打点上报数据、骑手相遇数据、骑手GPS数据,具体如下:平台要求骑手在接受订单、到达商家、领取订单、交付订单时主动在手机应用程序上报告订单进度,平台通过骑手的打点上报数据获得订单、骑手的实时状态;平台使用Beacon技术收集骑手相遇信息,其原理如下:通过手机应用程序,使骑手手机在其工作时间内通过BLE 5.0(蓝牙5.0)协议持续广播一个ID types并进行持续扫描以



感知蓝牙信号,再通过网络连接实时将扫描接收到的ID tuples上传到后端服务器,服务器接收到骑手ID和骑手接收到的ID tuples后,提取得到骑手相遇数据;平台通过骑手手机GPS定位获取骑手GPS数据。

[0012] 作为本发明的一种改进,步骤S2的多源特征提取与融合工作,从多源数据中提取了目标骑手目的地与目标骑手的相遇骑手的目的地多源组合特征,实现了特征层面的数据融合,具体工作如下:

[0013] 从多源数据中提取的三类特征分别是:相遇特征、GPS特征和激励特征,针对目标骑手的每个目的地,提取三类特征;针对目标骑手配送途中最近一次遇到的相遇骑手的每个目的地,提取两类特征(激励特征和相遇特征),然后取这两个骑手(目标骑手和相遇骑手)的目的地特征的笛卡尔乘积得到组合特征,即 $A \times B = \{(a, b) | a \in A \wedge b \in B\}$ 。每个组合特征代表目标骑手目的地和相遇骑手目的地的一种组合;具体来说,当目标骑手有N个目的地,而他在配送途中遇到的骑手有M个目的地时,模型首先从骑手打点上报数据、相遇数据以及GPS数据中提取出目标骑手N个目的地特征,以及相遇骑手M个目的地特征,然后得到 $M \times N$ 个组合特征。

[0014] 作为本发明的一种改进,三类特征具体定义如下:

[0015] A.相遇特征,相遇发生在从某个出发点前往目的地的路程中,通过将骑手相遇数据与骑手打点上报数据相关联,提取得到相遇事件发生时骑手的出发点位置等相遇特征;表二中展示了相遇特征的定义。假设目标骑手 $c_p$ 和相遇骑手 $c_e$ 的下一个目的地分别为 $d_i$ 和 $d_j$ ,如果根据目标骑手 $c_p$ 和相遇骑手 $c_e$ 的相遇特征 $x^E = \{L_o, L_d, t_e\}$ 发现他们不可能相遇,则推断下一目的地为 $d_i$ 和 $d_j$ 的假设是错误的,因此,相遇特征有助于验证下一目的地的预测;

[0016] B.GPS特征,假设下一个目的地为 $d_i$ ,则t时刻的骑手GPS特征包括从GPS数据中提取的骑手当前所在位置的地理位置 $L_g$ ,以及从打点上报数据中提取的 $L_o, L_d$ ,利用GPS特征 $x^G = \{L_g, L_o, L_d\}$ ,判断骑手当前的轨迹方向是否与到达目的地的方向 $d_i$ 一致,从而验证目的地 $d_i$ 是否为下一个目的地;

[0017] C.激励特征,对于骑手c,在t时刻,他有一组目的地 $D_{c,t}$ , $D_{c,t}$ 为骑手c在时间t的目的地集合。该目的地集合的大小为N,从打点上报数据中提取这些目的地的激励特征 $x^I = \{s, s_n, \bar{s}, t_{lo}, t_w, t_{ld}, t_g, v_p, v_c, v_{ps}\}$ ,激励特征主要由时间、空间、场景三类特征构成。其中骑手c,路径预测的目标骑手为 $c_p$ ,目标骑手的相遇骑手为 $c_e$ 。

[0018] 作为本发明的一种改进,步骤S3设计的ST(Specialized Transition)深度神经网络完成了模型层面的特征融合,从而实现了目标骑手的下一个目的地预测,具体工作如下:

[0019] 路径预测模块的关键部分是基于深度神经网络的ST网络,ST网络预测了每个骑手目的地组合的可能性,其结构如图2所示。ST网络对激励特征 $x^I$ 、相遇特征 $x^E$ 和GPS特征 $x^G$ 三类特征进行了不同的特征转换,每个特征转换由三层组成:输入层、隐藏层和输出层,经过特征转换得到的新特征向量最后通过全连接层连接在一起,利用sigmoid激活函数输出得分;

[0020] 经过特征转换得到的新特征向量k由 $k = K(x | W_h, W_o, b_h, b_o)$ 表示,其中 $K(\cdot)$ 为由 $W_h, W_o, b_h, b_o$ 参数化的特征转换函数, $K(\cdot)$ 分解为

[0021]  $h = \text{ReLU}(W_h x + b_h)$ ,

[0022]  $k = \text{ReLU}(W_o h + b_o)$ ;

[0023] 其中, $x$ 为输入特征向量, $h$ 为隐含层的输出, $W_h, b_h$ 为隐含层的权值和偏差, $W_o, b_o$ 为输出层的权值和偏差,隐含层和输出层使用的激活函数为ReLU,不同特征转换函数的参数是相互独立的;

[0024] 对于目标骑手的目的地 $d_i$ ,通过GPS特征转换得到新的GPS矢量 $k^G$ ,

$$[0025] \quad k^G = K(x_{d_i}^G | W_h^G, W_o^G, b_h^G, b_o^G);$$

[0026] 与骑手的GPS特征 $x_{d_i}^G$ 相比,它与 $d_i$ 被选为下一个目的地的可能性有更强的相关性,

[0027] 同样地,基于目的地激励特征 $x_{d_i}^I, x_{d_j}^I$ ,新的激励向量 $k_i^I, k_j^I$ 分别表示目的地 $d_i, d_j$ 被骑手 $c_p, c_e$ 选择的可能性;

$$[0028] \quad k_i^I = K(x_{d_i}^I | W_h^I, W_o^I, b_h^I, b_o^I),$$

$$[0029] \quad k_j^I = K(x_{d_j}^I | W_h^I, W_o^I, b_h^I, b_o^I);$$

[0030] ST网络的特点之一是共享目标骑手 $c_p$ 和相遇骑手 $c_e$ 的激励特征转换层参数。该设计减少了所需神经元的数量,有效地节省了训练成本。

[0031] 因为需要共同分析目标骑手和相遇骑手的相遇特征得到骑手相遇可能性,所以需将两个骑手 $c_p, c_e$ 的相遇特征 $x_{d_i}^E, x_{d_j}^E$ 拼接,然后输入到相遇特征转换层来获得新的相遇向量 $k^E$

$$[0032] \quad k^E = K([x_{d_i}^E, x_{d_j}^E] | W_h^E, W_o^E, b_h^E, b_o^E)。$$

[0033] 新向量 $k^E$ 与相遇概率密切相关,而相遇概率又与下一个目的地的正确性密切相关,

[0034] 最后,ST网络联合分析这些新的向量,并输出目标骑手目的地 $d_i$ 的最终预测得分 $p$ ,

$$[0035] \quad p = \delta(W_f[k^G, k^E, k_i^I, k_j^I] + b_f)。$$

[0036] 其中 $W_f, b_f$ 是全连接层的权值和偏差;

[0037] ST网络的预测任务是判断目的地组合是否正确,设 $y$ 为样本标签,值为0或1,使用交叉熵损失函数对网络进行训练,即损失函数为

$$[0038] \quad \text{Loss} = -[y \ln(p) + (1-y) \ln(1-p)],$$

[0039] 对于每个组合特征,通过ST网络得到预测得分,对得分进行排序,得分最高的组合特征所代表的目标骑手的目的地即为预测结果(即目标骑手的下一个目的地);

$$[0040] \quad x_{i,j}^{cb} = [x_{d_i}^G, x_{d_i}^E, x_{d_i}^I, x_{d_j}^E, x_{d_j}^I];$$

$$[0041] \quad p = M_{ST}(x^{cb}),$$

$$[0042] \quad \hat{d} = F_{tol}(\hat{x}^{cb}),$$

$$[0043] \quad \hat{x}^{cb} = \text{argmax}[M_{ST}(x_{i,j}^{cb})];$$

[0044] 整个路径预测过程可以用以上方程表示, $\hat{d}$ 表示预测得到的目标骑手下一个目的地, $M_{ST}(\cdot)$ 表示ST网络函数, $F_{tol}(\cdot)$ 表示组合特征 $x_{i,j}^{cb}$ 与目标骑手目的地 $d$ 的映射函数。

[0045] 相对于现有技术,本发明具有如下优点,1)本发明首次基于多源数据预测即时配送的骑手路径。基于多源数据的预测方法不仅提供了细粒度的时空信息,还有助于消除单

一数据源数据质量低的影响。该方法可以有效提高预测准确率。2) 本发明提出的特征转换层提取了多源特征中的有效信息,且降低模型复杂程度,增强了模型的学习能力,加快了模型的收敛速度,节省了模型训练时间。

### 附图说明

[0046] 图1为本发明整体框架示意图;

[0047] 图2为本发明的ST深度神经网络结构示意图。

### 具体实施方式

[0048] 为了加深对本发明的理解,下面结合附图对本实施例做详细的说明。

[0049] 实施例1:参见图1、图2,一种基于多源数据的即时配送路径预测方法,如图1所示为本发明技术的技术框架图。本发明提出的基于多源数据的即时配送路径预测技术,包括如下步骤:

[0050] S1.从即时配送平台提取骑手打点上报数据、骑手相遇数据、骑手GPS数据。具体包括以下工作。

[0051] 平台要求骑手在接受订单、到达商家、领取订单、交付订单时主动在手机应用程序上报告订单进度,平台通过骑手的打点上报数据获得订单、骑手的实时状态;

[0052] 平台使用Beacon技术收集骑手相遇信息,其原理如下:通过手机应用程序,使骑手手机在其工作时间内通过BLE 5.0(蓝牙5.0)协议持续广播一个ID tuples并进行持续扫描以感知蓝牙信号,再通过网络连接实时将扫描接收到的ID tuples上传到后端服务器,服务器接收到骑手ID和骑手接收到的ID tuples后,提取得到骑手相遇数据;

[0053] 平台通过骑手手机GPS定位获取骑手GPS数据。

[0054] S2.考虑多源数据的独立性与关联性,对多源数据进行多源特征提取与融合。包括以下工作:

[0055] 从骑手打点上报数据、相遇数据以及GPS数据中提取目标骑手N个目的地特征以及相遇骑手M个目的地特征。针对目标骑手的每个目的地,提取三类特征(相遇特征、GPS特征和激励特征)。而针对目标骑手最新遇到的相遇骑手的每个目的地,提取两类特征(激励特征和相遇特征)。然后取这两个骑手(目标骑手和相遇骑手)的目的地特征的笛卡尔乘积得到 $M \times N$ 个组合特征,即 $A \times B = \{(a, b) | a \in A \wedge b \in B\}$ 。每个组合特征代表目标骑手目的地和相遇骑手目的地的一种组合。

[0056] 三类特征的提取方式如下:

[0057] A.相遇特征。将骑手相遇数据与骑手打点上报数据相关联,提取得到相遇事件发生时骑手的出发点位置等相遇特征。相遇特征的具体定义见表2。

[0058] B.GPS特征。从GPS数据中提取骑手当前所在位置的地理位置 $L_g$ ,从打点上报数据中提取出发点、目的地的地理位置 $L_o, L_d$ ,得到GPS特征 $x^G = \{L_g, L_o, L_d\}$ ,其中:

[0059] L为地点的地理位置。 $L = (x, y)$ ,  $x, y$ 分别代表位置的经度坐标和维度坐标。

[0060] 表2本发明技术的相遇特征



	特征	符号	说明
[0061]	出发点	$L_o$	表示骑手出发点的地理位置。
	目的地	$L_d$	表示骑手目的地的地理位置。
	相遇事件	$t_e$	表示骑手从出发点出发到相遇时间发生的时间差。

[0062] C.激励特征。对于骑手 $c$ ,在 $t$ 时刻的目的地 $D_{c,t}$ ,从打点上报数据中提取集合 $D_{c,t}$ 中各个目的地的激励特征 $x^I = \{s, s_n, \bar{s}, t_{io}, t_u, t_{id}, t_g, v_p, v_c, v_{ps}\}$ 。激励特征主要由时间、空间、场景三类特征构成,具体定义见表3。

[0063] 表3本发明技术的激励特征

	特征	符号	说明
[0064]	距离	$s$	表示从骑手出发点到目的地 $d$ 的距离。
	是否最近	$s_n$	表示目的地 $d$ 是否是目的地集合中离骑手出发点最近的目的地,
			$s_n = E(s, \min(s^*))$ 。
[0065]	聚集程度	$\bar{s}$	表示从目的地 $d$ 到目的地集合中其它目的地的平均距离。
	剩余订单时间	$t_{io}$	表示当前时间离订单超时的剩余时间。
	是否最紧急	$t_u$	表示目的地 $d$ 是否是目的地集合中 $t_{io}$ 最短的目的地, $t_u = E(t_{io}, \min(t_{io}^*))$
	剩余目的地时间	$t_{id}$	假定保证订单不超时, $t_{id}$ 是当前时间离最晚到达目的地 $d$ 的剩余时间。
	时间紧急程度	$t_g$	表示目的地 $d$ 的时间紧急程度, $t_g = [\max(t_u^*) - t_u] / \max(t_u^*)$ 。
	地点类型	$v_p$	表示目的地 $d$ 的地点类型, 1 表示商店, 0 表示客户。
	地点总数	$v_c$	表示目的地集合 $D_{c,t}$ 的大小。
	地点类型占比	$v_{ps}$	表示目的地集合 $D_{c,t}$ 中与目的地 $d$ 地点类型相同地点的占比。

[0066] 其中: $E(\cdot)$ ,  $E(x, y)$  是判断相等的函数。当 $x=y$ ,  $E(x, y)=1$ , 否则 $E(x, y)=0$ 。

[0067] S3. 使用特征转换层提炼多源特征的高维特征表达, 基于深度神经网络预测即时配送路径。包括以下工作:

[0068] 构建深度神经网络ST, 其结构如图2所示。ST网络对组合特征中激励特征 $x^I$ 、相遇特征 $x^E$ 和GPS特征 $x^G$ 三类特征进行不同的特征转换。 $K(\cdot)$ 为由 $W_h, W_o, b_h, b_o$ 参数化的特征转换函数, $K(\cdot)$ 分解为

[0069]  $h = \text{ReLU}(W_h x + b_h)$ ,

[0070]  $k = \text{ReLU}(W_o h + b_o)$ 。

[0071] 其中, $x$ 为输入特征向量, $h$ 为隐含层的输出, $W_h, b_h$ 为隐含层的权值和偏差, $W_o, b_o$ 为

输出层的权值和偏差。隐含层和输出层使用的激活函数为ReLU。不同特征转换函数的参数相互独立。

[0072] 通过GPS特征转换将目标骑手的GPS特征 $x_{d_i}^G$ 转换得到新的GPS矢量 $k^G$ ,

[0073]  $k^G = K(x_{d_i}^G | W_h^G, W_o^G, b_h^G, b_o^G)$ 。

[0074] 通过激励特征转换将目的地激励特征 $x_{d_i}^I, x_{d_j}^I$ 转换为新的激励向量 $k_i^I, k_j^I$ ,

[0075]  $k_i^I = K(x_{d_i}^I | W_h^I, W_o^I, b_h^I, b_o^I)$ ,

[0076]  $k_j^I = K(x_{d_j}^I | W_h^I, W_o^I, b_h^I, b_o^I)$ 。

[0077] 通过将两个骑手 $c_p, c_e$ 的相遇特征 $x_{d_i}^E, x_{d_j}^E$ 拼接,输入到相遇特征转换层来获得新的相遇向量 $k^E$ ,

[0078]  $k^E = K([x_{d_i}^E, x_{d_j}^E] | W_h^E, W_o^E, b_h^E, b_o^E)$ 。

[0079] 通过全连接层联合分析新向量 $k^G, k^E, k_i^I, k_j^I$ ,输出目标骑手目的地 $d_i$ 的最终预测得分 $p$ ,

[0080]  $p = \delta(W_f[k^G, k^E, k_i^I, k_j^I] + b_f)$ 。

[0081] 其中 $W_f, b_f$ 是全连接层的权值和偏差。

[0082] 使用交叉熵损失函数对ST网络进行训练,损失函数公式为:

[0083]  $\text{Loss} = -[y \ln(p) + (1-y) \ln(1-p)]$ 。

[0084] 对于每一个组合特征,都通过训练好的ST网络得到预测得分。对得分进行排序,输出得分最高的组合特征所代表的目标骑手的目的地为预测结果(即目标骑手的下一个目的地)。用方程表示如下:

[0085]  $x_{i,j}^{cb} = [x_{d_i}^G, x_{d_i}^E, x_{d_i}^I, x_{d_j}^E, x_{d_j}^I]$ ,

[0086]  $p = M_{ST}(x^{cb})$ ,

[0087]  $\hat{d} = F_{tol}(\hat{x}^{cb})$ ,

[0088]  $\hat{x}^{cb} = \text{argmax}[M_{ST}(x_{i,j}^{cb})]$ ;

[0089]  $\hat{d}$ 表示预测得到的目标骑手下一个目的地, $M_{ST}(\cdot)$ 表示ST网络函数, $F_{tol}(\cdot)$ 表示组合特征 $x_{i,j}^{cb}$ 与目标骑手目的地 $d$ 的映射函数。

[0090] 需要说明的是上述实施例,并非用来限定本发明的保护范围,在上述技术方案的基础上所作出的等同变换或替代均落入本发明权利要求所保护的范围。

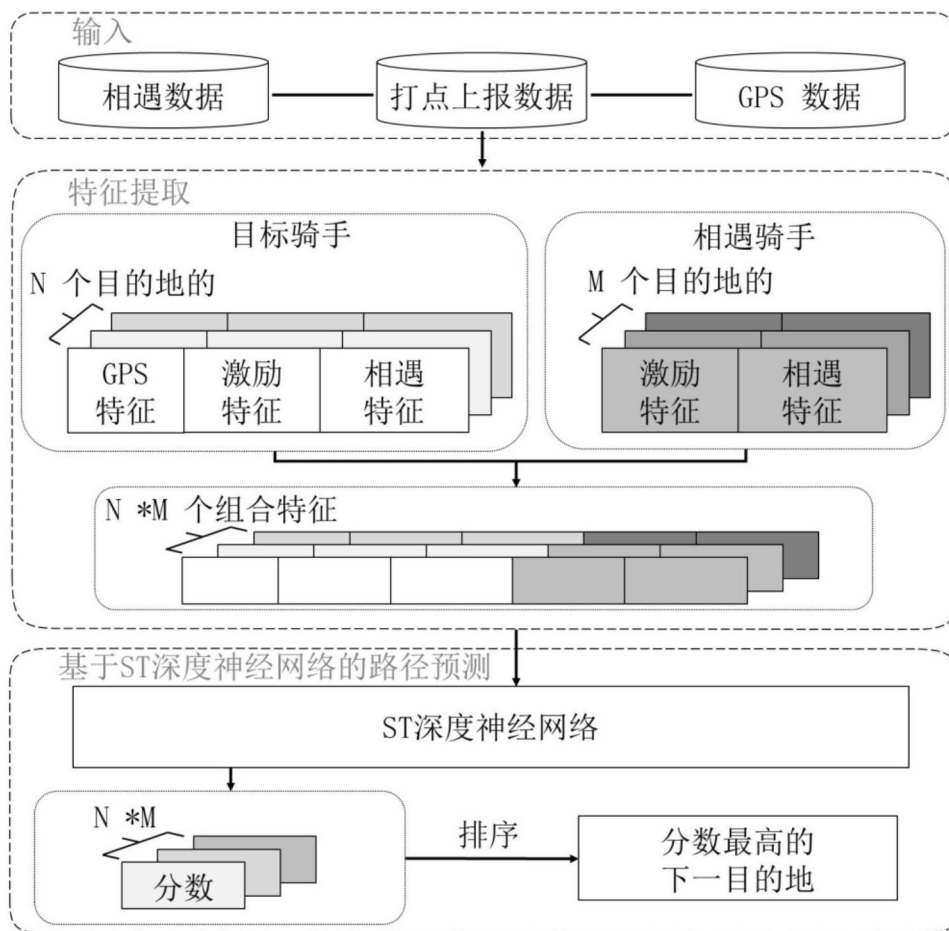


图1

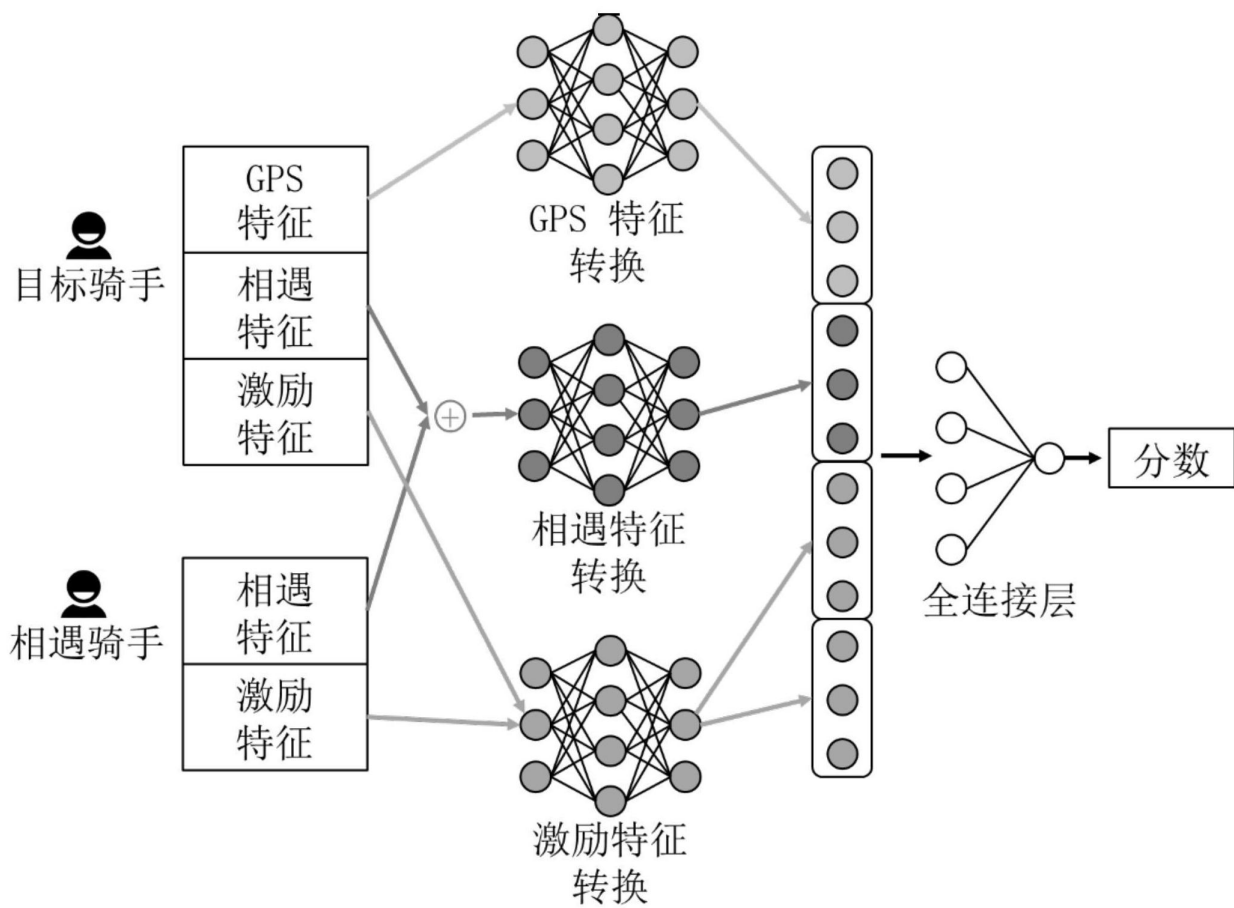


图2