



(12) 发明专利

(10) 授权公告号 CN 114095892 B

(45) 授权公告日 2024. 03. 05

(21) 申请号 202111363918.9

(22) 申请日 2021.11.17

(65) 同一申请的已公布的文献号

申请公布号 CN 114095892 A

(43) 申请公布日 2022.02.25

(73) 专利权人 东南大学

地址 211135 江苏省南京市麒麟科创园智
识路26号启迪城立业园04幢

(72) 发明人 王帅 刘韦 梅洛瑜 郑安琪

(74) 专利代理机构 南京众联专利代理有限公司

32206

专利代理师 杜静静

(51) Int. Cl.

H04W 4/33 (2018.01)

H04W 16/22 (2009.01)

G06F 18/22 (2023.01)

G06N 3/0464 (2023.01)

G06N 3/0442 (2023.01)

G06N 3/08 (2023.01)

(56) 对比文件

CN 108363478 A, 2018.08.03

CN 109831345 A, 2019.05.31

CN 111737107 A, 2020.10.02

CN 112035745 A, 2020.12.04

CN 112487217 A, 2021.03.12

US 2021142348 A1, 2021.05.13

孙伟, 陈平华. 基于知识图谱上下文的图注
意矩阵补全.《计算机工程与应用》.2021, 全文.

审查员 叶鼎晟

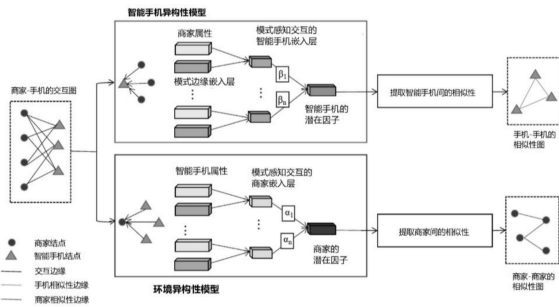
权利要求书1页 说明书9页 附图1页

(54) 发明名称

一种解决大规模信号异质性的室内人员状态检测的方法

(57) 摘要

本发明涉及一种解决大规模信号异质性的室内人员状态检测的方法, 所述方法包括以下步骤: 步骤1: 数据预处理, 为构建图准备数据; 步骤2: 通过相似性提取模块学习环境对蓝牙信号的影响模式和智能手机设备对蓝牙信号的影响模式之间的相似性; 步骤3: 基于影响模式之间的相似性, 通过模型参数预测模块预测未知场景下的状态检测模型参数; 该方案实现了基于图神经网络的大规模室内状态检测技术, 该技术分析了大规模场景下环境和智能手机设备对蓝牙信号造成的异质性影响模式, 并根据影响模式间的相似性来推断未知场景下的室内状态检测模型参数, 无需收集额外的数据及模型再训练, 最终室内状态检测的准确率和召回率分别达到93.62%和95.20%。



1. 一种解决大规模信号异质性的室内人员状态检测的方法,所述方法包括以下步骤:

步骤1:数据预处理,为构建图准备数据;

步骤2:通过相似性提取模块学习环境对蓝牙信号的影响模式和智能手机设备对蓝牙信号的影响模式之间的相似性;

步骤3:基于影响模式之间的相似性,通过模型参数预测模块预测未知场景下的状态检测模型参数;

其中,步骤2:通过相似性提取模块学习环境对蓝牙信号的影响模式和智能手机设备对蓝牙信号的影响模式之间的相似性,具体如下:首先以商店和智能手机为节点,利用历史蓝牙信号数据作为边信息,构建商店-手机交互图,利用环境异质性模型和智能手机异质性模型学习商店和智能手机节点的嵌入向量,其中包含节点对于蓝牙信号的影响模式,根据不同商店对于蓝牙信号影响模式和不同智能手机对于蓝牙信号影响模式间的相似性来分别构建商店相似性图和智能手机相似性图;

其中,步骤3:基于影响模式之间的相似性,通过模型参数预测模块预测未知场景下的状态检测模型参数,具体如下,首先以商店和智能手机为节点,利用基于历史蓝牙信号数据训练得到的状态检测模型参数作为边信息,构建商店-手机参数图,结合商店相似性图和智能手机相似性图,学习商店和智能手机节点的嵌入向量,将商店和智能手机节点的嵌入向量连接后输入到多层感知器中,预测出未知场景下的状态检测模型参数。

2. 根据权利要求1所述的解决大规模信号异质性的室内人员状态检测的方法,其特征在于,步骤1:数据预处理,为构建图准备数据,具体如下:将原始的蓝牙信号处理成一个合适的形式,作为商店-手机交互图的边信息,然后为带有标记数据的已有场景训练室内状态检测模型,并将模型参数作为商店-手机参数图的边信息。

一种解决大规模信号异质性的室内人员状态检测的方法

技术领域

[0001] 本发明涉及一种解决大规模信号异质性的室内人员状态检测的方法,属于通信技术领域。

背景技术

[0002] 近些年来,传感器在通信和智能设备上被广泛应用,如我们日常生活中常见的智能手表和手机等,可以收集到海量蕴含人类行为信息的传感器数据,通过挖掘和分析传感器数据,可以识别出室内人员状态(本文主要研究到达/离开状态检测)。室内人员感知的需求日益增加,同时也是很多应用的核心技术,如可以获取房屋占用率,有助于提高建筑的智能化,自动调整空调的采暖与通风功能以及控制照明,从而减少能源的消耗;为大型的商场提供实时客流量,有助于商家经营;对于即时配送平台,可以提供骑手到达离开时间,有助于后续骑手调度,减少订单逾期率;可见室内人员状态检测在很多领域都有广泛的应用前景。不可否认,目前已有许多与人员状态检测相关的工作,例如基于Wi-Fi的活动识别技术、基于BLE(蓝牙低功耗设备)的检测方案、基于射频识别技术和基于LED技术等解决方案。在所有技术中,蓝牙低功耗设备凭借其低成本、能源高效且无需硬件更新的优点,成为一个在大规模场景下很有前途的解决方案,现实世界中也部署了越来越多的BLE系统。例如,已有工作在上海12109名商家中部署了一个名为aBeacon的工业BLE系统以推断骑手到达和离开状态。虽然BLE设备可以在实验室等受控环境中表现突出,但是在室外环境下存在许多影响BLE系统性能的因素。首先,智能手机硬件和软件上的微小变化可能导致所收集的传感数据上的重大差异,也就是说,即使对相同状态,不同的智能手机的反应也有所不同。其次,蓝牙信号的传播路径受蓝牙低功耗设备部署的位置和周边环境的影响。这些因素以不同的方式同时影响蓝牙信号,从而导致相同状态下,智能手机收集到的传感数据是不同的。因此,由于环境和智能手机设备异质性对蓝牙信号的影响,直接在其他场景中使用由某个场景数据训练得到的室内评估模型是非常具有挑战性的。

发明内容

[0003] 本发明正是针对现有技术中存在的问题,提供一种解决大规模信号异质性的室内人员状态检测的方法,该技术方案提出了一个基于图神经网络的室内状态检测技术,首先设计了相似性提取模块,目的是学习环境 and 智能手机对蓝牙信号的异质性影响模式间存在的相似性。然后,基于异质性影响模式之间的相似性,设计了模型参数预测模块,来预测未知场景下的室内状态检测模型参数。最终可以得到未知场景下有效的状态检测模型,同时减轻异质性的影响。本发明设计并实现了基于图神经网络的室内状态检测技术,该技术通过学习环境和智能手机设备对蓝牙信号产生的异质性影响模式间的相似性来推断未知场景下的室内状态检测模型,最终室内状态检测的准确率和召回率分别达到93.62%和95.20%。

[0004] 为了实现上述目的,本发明的技术方案如下,一种解决大规模信号异质性的室内

人员状态检测的方法,其特征在于,所述方法包括以下步骤:

[0005] 步骤1:数据预处理,为构建图准备数据;

[0006] 步骤2:通过相似性提取模块学习环境对蓝牙信号的影响模式和智能手机设备对蓝牙信号的影响模式之间的相似性;

[0007] 步骤3:基于影响模式之间的相似性,通过模型参数预测模块预测未知场景下的状态检测模型参数。

[0008] 作为本发明的一种改进,步骤1:通数据预处理,为构建图准备数据,具体如下:

[0009] 由于数据收集过程中的会发生数据包丢失的情况,所以首先对RSSI时间序列进行插值,并利用Kalman过滤器去除异常值。为了将数据处理成商家-手机交互图G所需的格式,使用DTW(动态时间扭曲算法)来对齐同一智能手机检测到的所有RSSI时间序列,然后计算平均向量 $e_{ij} = \frac{1}{L} \sum_{l=1}^L r_l$ 作为交互边E的属性信息,其中 r_l 表示智能手机 v_j 在商家 u_i 检测到的第1个历史蓝牙信号时间序列,L是时间序列总数量。

[0010] 为了获取已知场景下商家-手机参数图所需的室内状态检测模型参数,将预处理的时间序列划分为一组长度为m,重叠50%的滑动窗口,将其输入室内状态检测模型。经过训练获得智能手机 v_j 和商家 u_i 的状态检测模型参数 e_{ij}^t ,并将其作为商家-手机参数图 E_t 的边属性信息。此外,商家属性数据集包括商家位置的纬度、经度和商家主要类别的信息。智能手机属性数据集包括智能手机型号和操作系统类型。

[0011] 作为本发明的一种改进,步骤2:通过相似性提取模块学习环境对蓝牙信号的影响模式和智能手机设备对蓝牙信号的影响模式之间的相似性,具体如下:

[0012] 首先构建了一个商家-手机交互图,以商家和智能手机为节点,历史蓝牙信号数据为边信息。为了获得环境和智能手机对蓝牙信号异质性影响模式间的相似性,首先需要分别学习包含商家和智能手机节点对于蓝牙信号的影响模式的嵌入向量 h_i 和 z_j 。

[0013] 设计了商家异质性模型来学习商家节点的嵌入向量。由于历史蓝牙信号包含了环境异构性的影响模式信息,图结构也包含了商店和智能手机之间丰富的交互信息。因此需联合交互作用和历史感知数据来进一步学习商家的嵌入向量 h_i 。

[0014] 为了考虑相邻智能手机节点在信息聚合过程中对商家节点的不同贡献,引入了基于边和节点属性的注意力机制。近智能手机结点 v_x 对商家结点 u_i 的贡献定义为:

[0015] $\alpha_{ix}^* = \sigma(W \cdot [\{g_{ix}, \forall x \in P(i)\} || s_i] + b)$

[0016] 其中,W和b是神经网络的权重和偏置项, σ 表示激活函数, s_i 是商家 u_i 的属性,P(i)代表一组与商家 u_i 交互的邻近智能手机结点, g_{ix} 是智能手机 v_x 的模式感知交互向量,可以共同捕获交互信息和商家的影响模式信息。现引入模式边嵌入向量 m_{ix} 来建模 g_{ix} ,首先输入边信息 e_{ix} 到一维卷积神经网络 ϕ_m ,即 $m_{ix} = \phi_m(e_{ix})$ 。然后,将它与智能手机 v_x 的属性结合并输入到MLP ϕ_v 中,即 $g_{ix} = \phi_v([m_{ix} || p_x])$ 。为了便于比较商家 u_i 的各个周边商家的贡献系数,

使用softmax函数完成标准化,即 $\alpha_{ix} = \frac{\exp(\alpha_{ix}^*)}{\sum_{x \in P(i)} \exp(\alpha_{ix}^*)}$ 。

[0017] 这样,商家 u_i 的嵌入向量 h_i 即可通过聚合不同贡献程度的邻居智能手机模式感知交互嵌入向量得到:

$$[0018] \quad h_i = \sigma(W \cdot \left\{ \sum_{x \in P(i)} \alpha_{ix} g_{ix} \right\} + b)$$

[0019] 设计了手机异质性模型来学习手机节点的嵌入向量。商店-手机交互图包含了丰富的交互式感知数据,其中包含了从不同商店角度反映的智能手机对蓝牙信号的影响模式。因此,应该同时考虑交互信息和感知数据来学习智能手机的嵌入向量。和商家异质性模型原理相似,引入注意力机制聚集与智能手机 v_j 交互的商店的模式感知交互向量,学习智能手机嵌入向量 z_j 。为了从数学上表示聚合过程,使用以下公式:

$$[0020] \quad z_j = \sigma(W \left\{ \sum_{o \in S(j)} \beta_{jo} a_{jo} \right\} + b)$$

[0021] 其中 $S(j)$ 是一组与智能手机 v_j 交互的邻居商店节点, a_{jo} 是一个商店的模式感知交互向量,它是通过将模式边嵌入向量 m_{jo} 和邻居商家 u_o 的属性 s_o 输入到MLP ϕ_u 中,即 $a_{jo} = \phi_u([m_{jo} || s_o])$ 。之后考虑商店的模式感知交互向量和智能手机 v_j 的属性 p_j 来学习邻居商店 u_o 的贡献系数 β_{jo} ,如下所示:

$$[0022] \quad \beta_{jo}^* = \sigma(W \cdot [\{a_{jo}, \forall o \in S(j)\} || p_j] + b)$$

$$[0023] \quad \beta_{jo} = \frac{\exp(\beta_{jo}^*)}{\sum_{o \in S(j)} \exp(\beta_{jo}^*)}$$

[0024] 获得商家和手机的嵌入向量后将它们输入到MLP中以重构边特征,即 $\hat{e}_{ij}^k = \sigma(W^{(k)} \cdot \hat{e}_{ij}^{(k-1)} + b^{(k)})$,其中 $\hat{e}_{ij}^{(0)} = [h_i || z_j]$, k 是隐藏层的索引,将最后一层的输出作为重构的边特征,有 $\hat{e}_{ij} = \hat{e}_{ij}^{(k)}$,然后,构造损失函数 $L_r = \frac{1}{|Q|} \sum_{i,j \in Q} \|\hat{e}_{ij} - e_{ij}\|_2$,其中 $|Q|$ 是已观察到的交互边数量, e_{ij} 作为商家-手机的交互图中的标准边。优化损失函数 L_r 以学习商家-手机的交互图中商家和智能手机的嵌入向量。

[0025] 现在,分别通过计算商店潜在因素之间和智能手机潜在因素之间的欧氏距离来衡量相似性,即 $dis_{ij}^h = \|h_i, h_j\|_2$, $dis_{ij}^z = \|z_i, z_j\|_2$ 。则商家相似性图 G^s 即可根据 dis_{ij}^h 的值构建。如果 $dis_{ij}^h \leq \varepsilon$,则判定在商家 u_i 和商家 u_j 间存在相似边缘,手机相似性图 G^p 的构建方式同理。

[0026] 作为本发明的一种改进,步骤3:基于影响模式之间的相似性,通过模型参数预测模块预测未知场景下的状态检测模型参数,具体如下,

[0027] 模型参数预测模块的输入为由不完整的商家-手机参数图 T ,商家相似图 G^s ,手机相似图 G^p 这三个子图组成的商家-手机异构图,输出为完整的商家-手机参数图,根据预测得到状态检测模型参数,得到未知场景下有效的室内状态检测模型。

[0028] 首先结合商家-手机参数图和商家相似性图来学习商家嵌入向量 h_i^t 。因为商店相似性图 G^s 包含了不同商店影响模式之间的相似性信息,可以帮助我们从更全面的角度了解商家的影响模式。具体来说,我们首先通过智能手机聚合从商家-手机参数图 T 中学习手机空间的商店嵌入向量 h_i^{t1} 。然后从商店相似图 G^s 中学习相似空间商店嵌入 h_i^{t2} 。最后,我们结合这两个嵌入,得到最终的商店嵌入向量 h_i^t 。

[0029] 为了获取手机空间的商家嵌入向量 h_i^{t1} ,需要聚集与商家 u_i 交互的智能手机 $P(i)$ 集合中的状态估计模型参数和交互信息,即 $h_i^{t1} = \sigma(W \cdot \{\sum_{a \in P(i)} \gamma_{ia} q_{ia}\} + b)$ 。其中, q_{ia} 是商家 u_i 和手机 v_a 间参数感知嵌入向量,用来建模商家 u_i 和手机 v_a 间的交互信息和模型参数信息。为了获得 q_{ia} ,先引入参数向量 n_{ia} 来建模到商家 u_i 和手机 v_a 间的模型参数信息,即 $n_{ia} = \varphi_p(e_{ia}^t)$ 。然后,将智能手机 v_a 的属性 p_a 与 n_{ia} 联合输入到MLP φ_v 中,获得 $q_{ia} = \varphi_v([n_{ia} || p_a])$ 。设计智能手机注意力机制 γ_{ia} 来表示与智能手机 v_a 的交互在获取手机空间的商店嵌入向量 h_i^{t1} 方面的重要性。只需将参数感知向量 q_{ia} 和商家属性 s_i 输入到单层的神经网络中,即可得到

$$[0030] \quad \gamma_{ia} = \frac{\exp(\sigma(W \cdot [q_{ia} || s_i] + b))}{\sum_{a \in P(i)} \exp(\sigma(W \cdot [q_{ia} || s_i] + b))}。$$

[0031] 由于商家集合 $C(i)$ 的影响模式与商家 u_i 相似,可以帮助我们对商家 u_i 的参数信息进行建模,所以我们捕获相似性信息来学习商家的嵌入向量。聚合商家 u_i 的相似的邻居商家集合 $C(i)$ 的手机空间的商家嵌入向量 h_c^{t1} ,来学习相似空间的商家嵌入向量 h_i^{t2} ,即

$$[0032] \quad h_i^{t2} = \sigma(W \cdot \left\{ \sum_{c \in C(i)} \mu_{ic} h_c^{t1} \right\} + b)$$

[0033] 然后,引入商家相似性邻居注意力机制 μ_{ic} ,联系连接向量 h_c^{t1} 及商家属性 s_i 来对相似的邻居商家节点的贡献度建模,即 $\mu_{ic} = \frac{\exp(\sigma(W \cdot [h_c^{t1} || s_i] + b))}{\sum_{c \in C(i)} \exp(\sigma(W \cdot [h_c^{t1} || s_i] + b))}$ 。

[0034] 将商家-手机参数图和商家相似度图结合考虑,得到最终的商店嵌入向量 h_i^t ,因为这两个图都从不同的方面提供了商店 u_i 的模型参数信息。我们将 h_i^{t1} 和 h_i^{t2} 输入到MLP中,以获得最终的商店嵌入向量 h_i^t , $h_i^{t(k)} = \sigma(W^{(k)} \cdot h_i^{t(k-1)} + b^{(k)})$,其中 $h_i^{t(0)} = [h_i^{t1} || h_i^{t2}]$ 。

[0035] 获取手机嵌入向量 z_j^t 的过程与获取商店嵌入向量的过程类似,首先基于商家注意力机制 ρ 从商家-手机参数图 T 中聚合商家 $S(j)$ 的交互信息和模型参数信息来学习商家空间的智能手机嵌入向量 z_j^{t1} 。然后,基于智能手机相似邻居注意力机制 τ 从手机相似图 G^p 中聚合 v_j 的相似邻居智能手机 $N(j)$ 的商家空间嵌入向量,得到相似空间的智能手机嵌入向量 z_j^{t2} 。最后将 z_j^{t1} 和 z_j^{t2} 联合输入MLP,获得最终的智能手机嵌入向量 z_j^t 。

[0036] 最后利用商家嵌入向量 h_i^t 和智能手机嵌入向量 z_j^t 来预测未知场景下的有效模型参数。将两个向量连接后输入MLP,以预测缺失的模型参数 \hat{e}_{ij}^t , $\hat{e}_{ij}^{t(k)} = \sigma(W^{(k)} \cdot e_{ij}^{t(k-1)} + b^{(k)})$,其中 $e_{ij}^{t(0)} = [h_i^t || z_j^t]$ 。

[0037] 为权衡商家-手机参数图 T 中缺失的参数边缘预测任务和状态检测任务,构建以下两个常见的损失函数。对于参数边缘预测任务构建函数如下:

$$[0038] \quad L_p = \frac{1}{|O|} \sum_{ij \in O} \|\hat{e}_{ij}^t - e_{ij}^t\|_2$$

[0039] 其中, $|O|$ 是训练集中商家和智能手机之间未知参数边缘数量, \hat{e}_{ij}^t 和 e_{ij}^t 分别是这些商家和智能手机之间预测的室内状态检测模型参数和标准室内状态检测模型参数。

[0040] 对于状态检测任务, 先把智能手机 v_j 位于商家 u_i 时检测到的RSSI时间序列 r_{ij} 输入到由 \hat{e}_{ij}^t 参数组成的状态检测模型CNN-LSTM中, 得到为该时间序列预测的状态概率, 表示为 $y' = \text{ConvLSTM}(r_{ij}; \hat{e}_{ij}^t)$, 此时损失函数可表示为

$$[0041] \quad L_s = \frac{1}{N} \sum_{i=1}^N \sum_{m=1}^M -y_{im} \log y'_{im}$$

[0042] 其中 y_i 是标准状态, N 为序列的数量, M 为状态数量,

[0043] 最终目标是提高状态检测的性能, 因此总体损失函数 $L = L_p + \eta L_s$, 其中 η 是一个权衡参数。训练过程采用了Adam优化器。为了防止过拟合, 对模型应用dropout策略。

[0044] 为了获得用于商家-手机的参数图构建的每个源域的状态估计模型参数, 并降低训练成本, 首先利用源域的所有标记数据来训练一个统一的状态估计模型。然后利用每个源域的数据微调统一模型的CNN层, 以获取每个源域的状态估计模型参数。

[0045] 最后, 为了预测缺失的参数边缘, 优化了损失函数 L , 以联合训练参数边缘预测任务和状态估计任务。训练过程采用了Adam优化器。为了防止过拟合, 对模型应用dropout策略。

[0046] 总而言之, 本发明在基于图神经网络实现方式下, 分析了蓝牙信号中产生异构的影响模式间的相似性来推断未知情景下的影响模式, 省略了额外的数据收集及模型再训练工作, 成功的预测了新的目标区域里室内状态估计模型的参数。

[0047] 相对于现有技术, 本发明具有如下优点, 该技术方案设计并实现了基于图神经网络的室内状态估计技术, 该技术分析了蓝牙信号中产生异构的影响模式间的相似性来推断未知情景下的影响模式, 省略了额外的数据收集及模型再训练工作, 预测新的目标区域里室内状态估计模型的参数, 状态估计的精确率和召回率达到93.62%和95.20%。

附图说明

[0048] 图1为相似性提取模块结构示意图;

[0049] 图2为参数预测模块结构示意图。

具体实施方式

[0050] 实施例: 一种解决大规模信号异质性的室内人员状态检测的方法, 所述方法包括以下步骤:

[0051] 步骤1: 数据预处理, 为构建图准备数据;

[0052] 步骤2: 通过相似性提取模块学习环境对蓝牙信号的影响模式和智能手机设备对蓝牙信号的影响模式之间的相似性;

[0053] 步骤3: 基于影响模式之间的相似性, 通过模型参数预测模块预测未知场景下的状

态检测模型参数。

[0054] 其中,步骤1:通数据预处理,为构建图准备数据,具体如下:

[0055] 由于数据收集过程中的会发生数据包丢失的情况,所以首先对RSSI时间序列进行插值,并利用Kalman过滤器去除异常值。为了将数据处理成商家-手机交互图G所需的格式,使用DTW(动态时间扭曲算法)来对齐同一智能手机检测到的所有RSSI时间序列,然后计算平均向量 $e_{ij} = \frac{1}{L} \sum_{l=1}^L r_l$ 作为交互边E的属性信息,其中 r_1 表示智能手机 v_j 在商家 u_i 检测到的第1个历史蓝牙信号时间序列,L是时间序列总数量。

[0056] 为了获取已知场景下商家-手机参数图所需的室内状态检测模型参数,将预处理的时间序列划分为一组长度为m,重叠50%的滑动窗口,将其输入室内状态检测模型。经过训练获得智能手机 v_j 和商家 u_i 的状态检测模型参数 e_{ij}^t ,并将其作为商家-手机参数图 E_t 的边属性信息。此外,商家属性数据集包括商家位置的纬度、经度和商家主要类别的信息。智能手机属性数据集包括智能手机型号和操作系统类型。

[0057] 其中,步骤2:通过相似性提取模块学习环境对蓝牙信号的影响模式和智能手机设备对蓝牙信号的影响模式之间的相似性,具体如下:

[0058] 首先构建了一个商家-手机交互图,以商家和智能手机为节点,历史蓝牙信号数据为边信息。为了获得环境和智能手机对蓝牙信号异质性影响模式间的相似性,首先需要分别学习包含商家和智能手机节点对于蓝牙信号的影响模式的嵌入向量 h_i 和 z_j 。

[0059] 设计了商家异质性模型来学习商家节点的嵌入向量。由于历史蓝牙信号包含了环境异构性的影响模式信息,图结构也包含了商店和智能手机之间丰富的交互信息。因此需联合交互作用和历史感知数据来进一步学习商家的嵌入向量 h_i 。

[0060] 为了考虑相邻智能手机节点在信息聚合过程中对商家节点的不同贡献,引入了基于边和节点属性的注意力机制。近智能手机结点 v_x 对商家结点 u_i 的贡献定义为:

$$[0061] \quad \alpha_{ix}^* = \sigma(W \cdot [\{g_{ix}, \forall x \in P(i)\} || s_i] + b)$$

[0062] 其中,W和b是神经网络的权重和偏置项, σ 表示激活函数, s_i 是商家 u_i 的属性,P(i)代表一组与商家 u_i 交互的邻近智能手机结点, g_{ix} 是智能手机 v_x 的模式感知交互向量,可以共同捕获交互信息和商家的影响模式信息。现引入模式边嵌入向量 m_{ix} 来建模 g_{ix} ,首先输入边信息 e_{ix} 到一维卷积神经网络 ϕ_m ,即 $m_{ix} = \phi_m(e_{ix})$ 。然后,将它与智能手机 v_x 的属性结合并输入到MLP ϕ_v 中,即 $g_{ix} = \phi_v([m_{ix} || p_x])$ 。为了便于比较商家 u_i 的各个周边商家的贡献系数,

使用softmax函数完成标准化,即
$$\alpha_{ix} = \frac{\exp(\alpha_{ix}^*)}{\sum_{x \in P(i)} \exp(\alpha_{ix}^*)}。$$

[0063] 这样,商家 u_i 的嵌入向量 h_i 即可通过聚合不同贡献程度的邻居智能手机模式感知交互嵌入向量得到:

$$[0064] \quad h_i = \sigma(W \cdot \left\{ \sum_{x \in P(i)} \alpha_{ix} g_{ix} \right\} + b)$$

[0065] 设计了手机异质性模型来学习手机节点的嵌入向量。商店-手机交互图包含了丰富的交互式感知数据,其中包含了从不同商店角度反映的智能手机对蓝牙信号的影响模式。因此,应该同时考虑交互信息和感知数据来学习智能手机的嵌入向量。和商家异质性模

型原理相似,引入注意力机制聚集与智能手机 v_j 交互的商店的模式感知交互向量,学习智能手机嵌入向量 z_j 。为了从数学上表示聚合过程,使用以下公式:

$$[0066] \quad z_j = \sigma(W \left\{ \sum_{o \in S(j)} \beta_{jo} a_{jo} \right\} + b)$$

[0067] 其中 $S(j)$ 是一组与智能手机 v_j 交互的邻居商店节点, a_{jo} 是一个商店的模式感知交互向量,它是通过将模式边嵌入向量 m_{jo} 和邻居商家 u_o 的属性 s_o 输入到MLP ϕ_u 中,即 $a_{jo} = \phi_u([m_{jo} || s_o])$ 。之后考虑商店的模式感知交互向量和智能手机 v_j 的属性 p_j 来学习邻居商店 u_o 的贡献系数 β_{jo} ,如下所示:

$$[0068] \quad \beta_{jo}^* = \sigma(W \cdot [\{a_{jo}, \forall o \in S(j)\} || p_j] + b)$$

$$[0069] \quad \beta_{jo} = \frac{\exp(\beta_{jo}^*)}{\sum_{o \in S(j)} \exp(\beta_{jo}^*)}.$$

[0070] 获得商家和手机的嵌入向量后将它们输入到MLP中以重构边特征,即 $\hat{e}_{ij}^k = \sigma(W^{(k)} \cdot \hat{e}_{ij}^{(k-1)} + b^{(k)})$,其中 $\hat{e}_{ij}^{(0)} = [h_i || z_j]$, k 是隐藏层的索引,将最后一层的输出作为重构的边特征,有 $\hat{e}_{ij} = \hat{e}_{ij}^{(k)}$,然后,构造损失函数 $L_r = \frac{1}{|Q|} \sum_{i,j \in Q} \|\hat{e}_{ij} - e_{ij}\|_2$,其中 $|Q|$ 是已观察到的交互边数量, e_{ij} 作为商家-手机的交互图中的标准边。优化损失函数 L_r 以学习商家-手机的交互图中商家和智能手机的潜在因子。

[0071] 现在,分别通过计算商店潜在因素之间和智能手机潜在因素之间的欧氏距离来衡量相似性,即 $dis_{ij}^h = \|h_i, h_j\|_2$, $dis_{ij}^z = \|z_i, z_j\|_2$ 。则商家相似性图 G^s 即可根据 dis_{ij}^h 的值构建。如果 $dis_{ij}^h \leq \varepsilon$,则判定在商家 u_i 和商家 u_j 间存在相似边缘,手机相似性图 G^p 的构建方式同理。

[0072] 其中,步骤3:基于影响模式之间的相似性,通过模型参数预测模块预测未知场景下的状态检测模型参数,具体如下,

[0073] 模型参数预测模块的输入为由不完整的商家-手机参数图 T ,商家相似图 G^s ,手机相似图 G^p 这三个子图组成的商家-手机异构图,输出为完整的商家-手机参数图,根据预测得到状态检测模型参数,得到未知场景下有效的室内状态检测模型。

[0074] 首先结合商家-手机参数图和商家相似性图来学习商家嵌入向量 h_i^t 。因为商店相似性图 G^s 包含了不同商店影响模式之间的相似性信息,可以帮助我们从更全面的角度了解商家的影响模式。具体来说,我们首先通过智能手机聚合从商家-手机参数图 T 中学习手机空间的商店嵌入向量 h_i^{t1} 。然后从商店相似图 G^s 中学习相似空间商店嵌入 h_i^{t2} 。最后,我们结合这两个嵌入,得到最终的商店嵌入向量 h_i^t 。

[0075] 为了获取手机空间的商家嵌入向量 h_i^{t1} ,需要聚集与商家 u_i 交互的智能手机 $P(i)$ 集合中的状态估计模型参数和交互信息,即 $h_i^{t1} = \sigma(W \cdot \{\sum_{a \in P(i)} \gamma_{ia} q_{ia}\} + b)$ 。其中, q_{ia} 是商家 u_i 和手机 v_a 间参数感知嵌入向量,用来建模商家 u_i 和手机 v_a 间的交互信息和模型参数信息。为了获得 q_{ia} ,先引入参数向量 n_{ia} 来建模到商家 u_i 和手机 v_a 间的模型参数信息,即 $n_{ia} = \phi_p(e_{ia}^t)$ 。

然后,将智能手机 v_a 的属性 p_a 与 n_{ia} 联合输入到MLP φ_v 中,获得 $q_{ia} = \varphi_v([n_{ia}||p_a])$ 。设计智能手机注意力机制 γ_{ia} 来表示与智能手机 v_a 的交互在获取手机空间的商店嵌入向量 h_i^{t1} 方面的重要性。只需将参数感知向量 q_{ia} 和商家属性 s_i 输入到单层的神经网络中,即可得到

$$[0076] \quad \gamma_{ia} = \frac{\exp(\sigma(W \cdot [q_{ia}||s_i] + b))}{\sum_{a \in P(i)} \exp(\sigma(W \cdot q_{ia}||s_i] + b))}。$$

[0077] 由于商家集合 $C(i)$ 的影响模式与商家 u_i 相似,可以帮助我们对商家 u_i 的参数信息进行建模,所以我们捕获相似性信息来学习商家的嵌入向量。聚合商家 u_i 的相似的邻居商家集合 $C(i)$ 的手机空间的商家嵌入向量 h_i^{t1} ,来学习相似空间的商家嵌入向量 h_i^{t2} ,即

$$[0078] \quad h_i^{t2} = \sigma(W \cdot \left\{ \sum_{c \in C(i)} \mu_{ic} h_c^{t1} \right\} + b)$$

[0079] 然后,引入商家相似性邻居注意力机制 μ_{ic} ,联系连接向量 h_c^{t1} 及商家属性 s_i 来对相似的邻居商家节点的贡献度建模,即

$$\mu_{ic} = \frac{\exp(\sigma(W \cdot [h_c^{t1}||s_i] + b))}{\sum_{c \in C(i)} \exp(\sigma(W \cdot [h_c^{t1}||s_i] + b))}。$$

[0080] 将商家-手机参数图和商家相似度图结合考虑,得到最终的商店嵌入向量 h_i^t ,因为这两个图都从不同的方面提供了商店 u_i 的模型参数信息。我们将 h_i^{t1} 和 h_i^{t2} 输入到MLP中,以获得最终的商店嵌入向量 h_i^t , $h_i^{t(k)} = \sigma(W^{(k)} \cdot h_i^{t(k-1)} + b^{(k)})$,其中 $h_i^{t(0)} = [h_i^{t1}||h_i^{t2}]$ 。

[0081] 获取手机嵌入向量 z_j^t 的过程与获取商店嵌入向量的过程类似,首先基于商家注意力机制 ρ 从商家-手机参数图 T 中聚合商家 $S(j)$ 的交互信息和模型参数信息来学习商家空间的智能手机嵌入向量 z_j^{t1} 。然后,基于智能手机相似邻居注意力机制 τ 从手机相似图 G^p 中聚合 v_j 的相似邻居智能手机 $N(j)$ 的商家空间嵌入向量,得到相似空间的智能手机嵌入向量 z_j^{t2} 。最后将 z_j^{t1} 和 z_j^{t2} 联合输入MLP,获得最终的智能手机嵌入向量 z_j^t 。

[0082] 最后利用商家嵌入向量 h_i^t 和智能手机嵌入向量 z_j^t 来预测未知场景下的有效模型参数。将两个向量连接后输入MLP,以预测缺失的模型参数 \hat{e}_{ij}^t , $\hat{e}_{ij}^{t(k)} = \sigma(W^{(k)} \cdot e_{ij}^{t(k-1)} + b^{(k)})$,其中 $e_{ij}^{t(0)} = [h_i^t||z_j^t]$ 。

[0083] 为权衡商家-手机参数图 T 中缺失的参数边缘预测任务和状态检测任务,构建以下两个常见的损失函数。对于参数边缘预测任务构建函数如下:

$$[0084] \quad L_p = \frac{1}{|O|} \sum_{i,j \in O} \|\hat{e}_{ij}^t - e_{ij}^t\|_2$$

[0085] 其中, $|O|$ 是训练集中商家和智能手机之间未知参数边缘数量, \hat{e}_{ij}^t 和 e_{ij}^t 分别是这些商家和智能手机之间预测的室内状态检测模型参数和标准室内状态检测模型参数。

[0086] 对于状态检测任务,先把智能手机 v_j 位于商家 u_i 时检测到的RSSI时间序列 r_{ij} 输入到由 \hat{e}_{ij}^t 参数组成的状态检测模型CNN-LSTM中,得到为该时间序列预测的状态概率,表示为

$y' = \text{ConvLSTM}(r_{ij}; \hat{e}_{ij}^t)$, 此时损失函数可表示为

$$[0087] \quad L_s = \frac{1}{N} \sum_{i=1}^N \sum_{m=1}^M -y_{im} \log y'_{im}$$

[0088] 其中 y_i 是标准状态, N 为序列的数量, M 为状态数量,

[0089] 最终目标是提高状态检测的性能, 因此总体损失函数 $L = L_p + \eta L_s$, 其中 η 是一个权衡参数。训练过程采用了Adam优化器。为了防止过拟合, 对模型应用dropout策略。

[0090] 为了获得用于商家-手机的参数图构建的每个源域的状态估计模型参数, 并降低训练成本, 首先利用源域的所有标记数据来训练一个统一的状态估计模型。然后利用每个源域的数据微调统一模型的CNN层, 以获取每个源域的状态估计模型参数。

[0091] 最后, 为了预测缺失的参数边缘, 优化了损失函数 L , 以联合训练参数边缘预测任务和状态估计任务。训练过程采用了Adam优化器。为了防止过拟合, 对模型应用dropout策略。

[0092] 总而言之, 本发明在基于图神经网络实现方式下, 分析了蓝牙信号中产生异构的影响模式间的相似性来推断未知情景下的影响模式, 省略了额外的数据收集及模型再训练工作, 成功的预测了新的目标区域里室内状态估计模型的参数。

[0093] 具体实施例1:

[0094] 用于快递类型的即时配送业务。

[0095] 在新区域内, 可利用源域的历史蓝牙数据信息建立相似性预测模型技术预测室内人员状态。

[0096] 例如, 应用于外卖业务、跑腿业务等。

[0097] 具体实施例2:

[0098] 用于商场人员室内状态检测。

[0099] 本方案技术可用于检测商场内实时人员流动状况。

[0100] 例如, 应用于营业统计、流动估计等。

[0101] 具体实施例3:

[0102] 用于物流方面的配送业务。

[0103] 本方案可用于检测货车司机的工作状态, 利用历史数据预测司机的接单进度。

[0104] 例如, 应用于货物运输、搬家等。

[0105] 具体实施例4:

[0106] 用于快车行业的司机状态检测。

[0107] 本方案可利用源域的历史蓝牙数据信息建立相似性预测模型技术预测快车司机的状态。

[0108] 例如, 应用于打车服务等。

[0109] 需要说明的是上述实施例, 并非用来限定本发明的保护范围, 在上述技术方案的基础上所作出的等同变换或替代均落入本发明权利要求所保护的范围。

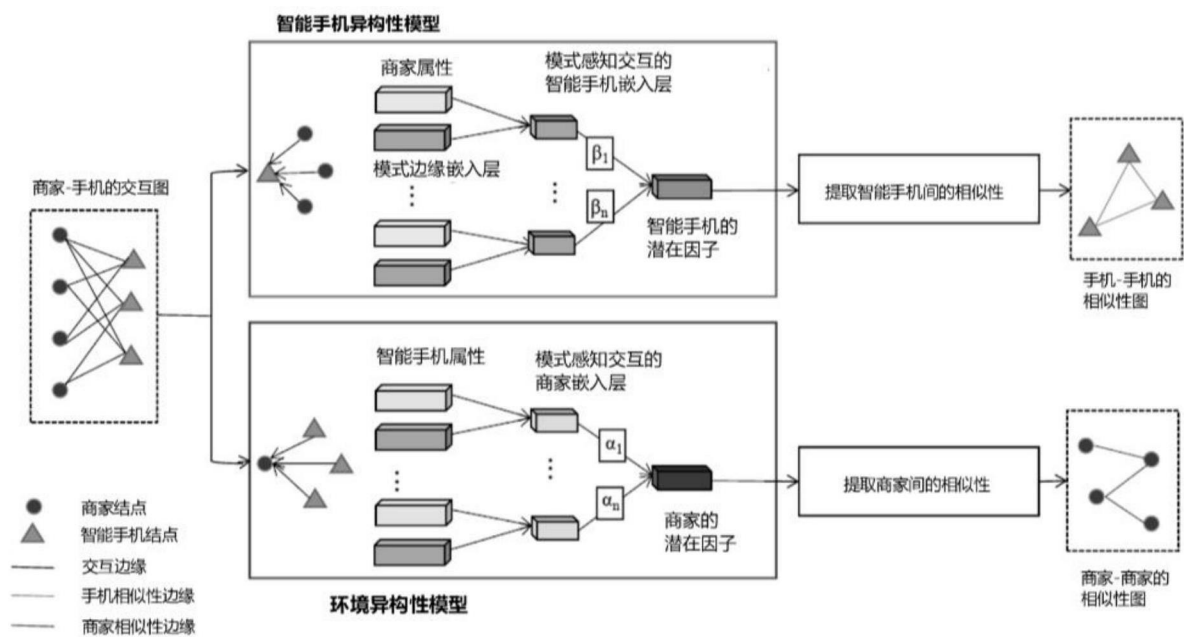


图1

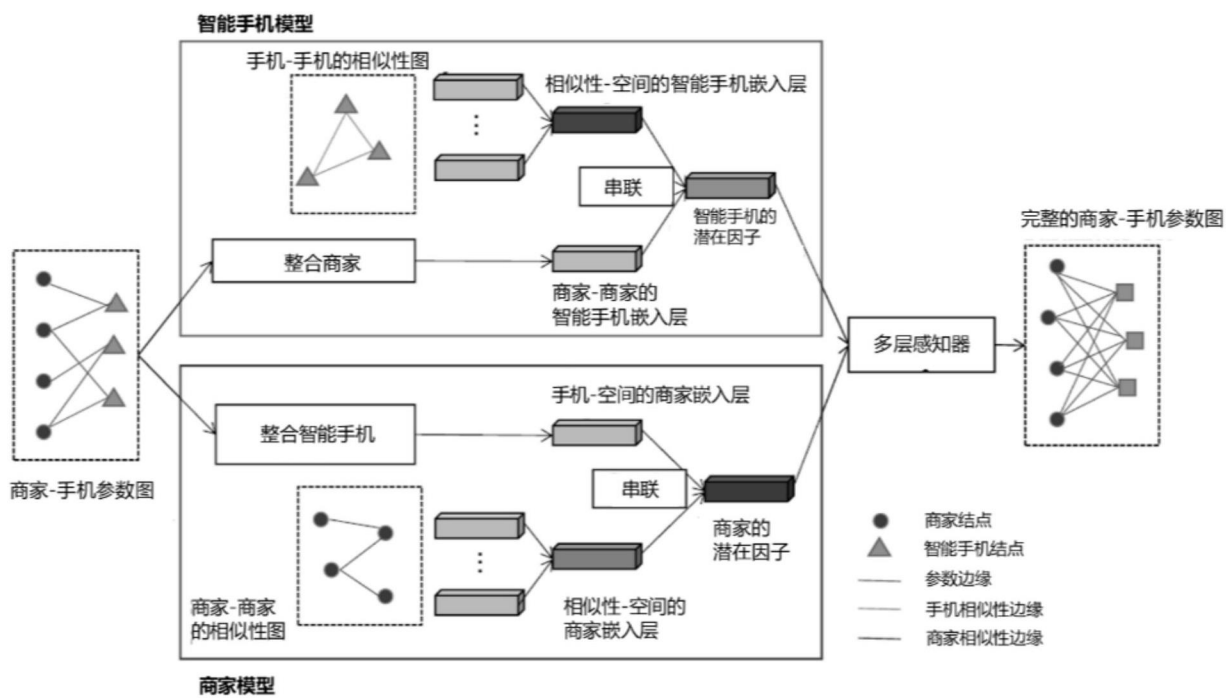


图2